



AULA DE REVISÃO


Coleta · ETL/ELT · Manipulação · Regex · Modelagem Preditiva · Lean Startup

O que é Ciência de Dados · Ciclo de Vida · Tipos de Dados

O que é Ciência de Dados?

Área interdisciplinar que combina estatística, programação e conhecimento de domínio para extrair insights e valor de dados.

Os 3 Pilares da Ciência de Dados



Ciclo de Vida dos Dados



Tipos de Dados por Estrutura

Os dados coletados diferem em grau de organização — o que influencia como são armazenados, processados e analisados.

DADOS ESTRUTURADOS

Planilhas / Tabelas SQL

Organizados em linhas e colunas com esquema fixo e tipos de dados definidos. Facilmente consultáveis com SQL.

- Tabelas de banco relacional (MySQL, PostgreSQL)
- Dados de CRM e ERP
- Registros de transações financeiras

Ferramentas: MySQL · PostgreSQL · SQLite
· Pandas DataFrame

DADOS SEMIESTRUTURADOS

JSON / XML / Logs

Possuem marcadores ou tags para separar elementos (schema flexível), mas não se encaixam em tabelas rígidas.

- JSON e XML — respostas de APIs REST
- Logs de sistemas e servidores
- E-mails e documentos HTML
- Dados de sensores IoT

Ferramentas: MongoDB · Elasticsearch ·
Apache Avro · Parquet

DADOS NÃO ESTRUTURADOS

Texto / Imagem / Vídeo

Sem formato predefinido — representam ~80% de todos os dados gerados. Requerem técnicas especializadas de processamento.

- Texto livre: e-mails, posts, PDFs, transcrições
- Imagens e vídeos (câmeras, satélites)
- Áudio (podcasts, chamadas de suporte)
- Dados de redes sociais


Ferramentas: NLP · CV (OpenCV) · Data
Lakes · Databricks

Conceito · Pipeline · Tipos · Métodos · Amostragem · Ética · Tendências

Coleta de Dados — Conceito e Pipeline

É o processo sistemático de reunir dados brutos de fontes diversas para análise e geração de insights.

O Pipeline de Dados



Fundamentos: Sistemático (processo reproduzível) · Proposital (dados rastreáveis a um objetivo) · Foco na Qualidade (precisão, integridade, consistência)

Coleta = 'o quê' | Ingestão = 'como mover' | Diferença fundamental ao planejar pipelines

Tipos de Dados para Coleta — Qualitativo, Quantitativo e Misto

QUALITATIVOS

- Descrevem qualidades, razões, opiniões e motivações
- Não numérico — buscam compreender o 'porquê'
- Ex: transcrições de entrevistas, notas de observação
- Métodos: entrevistas, grupos focais, etnografia
- Análise: categorização, interpretação de padrões

QUANTITATIVOS

- Dados numéricos — medidos, contados e analisados
- Buscam responder 'quanto', 'com que frequência'
- Ex: vendas, idade, temperatura, resultados de pesquisa
- Métodos: questionários, sensores, APIs, experimentos
- Análise: estatística descritiva e inferencial

MISTOS

- Combinação de abordagens qualitativas e quantitativas
- Proporciona compreensão mais abrangente
- Ex: pesquisa com escala Likert + perguntas abertas
- Triangulação: valida resultados por múltiplos métodos
- Mais robusto, porém mais complexo de executar

Abordagem mista combina os dois tipos para maior riqueza analítica — comum em pesquisas acadêmicas e empresariais robustas.

Métodos de Coleta — Primários, Secundários e Automatizados

PRIMÁRIOS — Fonte Original

- Surveys/Questionários: Google Forms, SurveyMonkey, Qualtrics, ODK
- Entrevistas: estruturadas, semiestruturadas, não estruturadas (Otter.ai, Rev)
- Experimentos controlados e Testes A/B (Optimizely, VWO)
- Observação direta e grupos focais
- Coleta por dispositivos IoT e wearables em tempo real

SECUNDÁRIOS — Dados Reutilizados

- Fontes internas: CRM, logs de sistemas, bancos de dados corporativos
- Fontes externas: datasets públicos (IBGE, governo, Kaggle)
- Relatórios do setor e estudos acadêmicos
- Feeds de API: Twitter, Google Analytics, Open Data
- Web scraping: BeautifulSoup, Scrapy, Selenium

AUTOMATIZADOS — Alto Volume

- Analytics web: GA4, Mixpanel, Amplitude — clickstream contínuo
- IoT e sensores: AWS IoT Hub, Azure IoT — dados de dispositivos
- Logs de sistema: métricas de performance, eventos de app
- Streaming em tempo real: Apache Kafka, AWS Kinesis, Pub/Sub
- Business Intelligence: Tableau, Power BI, Looker

Métodos Qualitativos de Coleta em Detalhe

Métodos qualitativos buscam compreender comportamentos, motivações e contextos — fundamentais em pesquisa de UX, ciências sociais e validação de produtos.

Entrevistas

- Estruturada: roteiro fixo, comparação entre respondentes
- Semiestruturada: roteiro flexível, aprofunda tópicos emergentes
- Não estruturada: conversa livre, explora sem limitações

Quando: necessário compreender perspectiva individual em profundidade

Observação Direta

- Participante: pesquisador se envolve nas atividades do grupo
- Não participante: pesquisador mantém distância, apenas observa
- Etnografia: imersão profunda em um grupo cultural por longo período

Quando: comportamento natural diverge do reportado verbalmente

Grupos Focais

- Discussão em grupo (6-12 pessoas) com moderador
- Explora percepções coletivas e consensos/divergências
- Eficiente para testar conceitos e novas ideias

Quando: entender como um grupo percebe um produto/serviço

Análise de Conteúdo

- Método sistemático para analisar textos, mídias e artefatos
- Identifica padrões, temas e frequências em material qualitativo
- Base para NLP (Natural Language Processing) em larga escala

Quando: grande volume de texto ou mídia precisa ser categorizado

Amostragem — Probabilística e Não Probabilística

Amostragem é a seleção de um subconjunto de indivíduos de uma população maior para representar o todo — fundamental para qualquer análise estatística.

PROBABILÍSTICA — Todos têm chance de ser selecionados

Aleatória Simples

Cada elemento tem igual probabilidade de seleção. Ex: sorteio de participantes.

Estratificada

Divide a população em subgrupos (estratos) e sorteia dentro de cada um. Garante representatividade.

Por Conglomerados

Seleciona grupos naturais (ex: turmas, bairros) e analisa todos os elementos do grupo sorteado.

Sistemática

Seleciona de k em k elementos de uma lista ordenada (ex: 1 em cada 10).

NÃO PROBABILÍSTICA — Sem seleção aleatória

Por Conveniência

Seleciona os mais acessíveis. Rápido e barato, mas sujeito a viés de seleção.

Por Cotas

Seleciona participantes até atingir cotas definidas por característica (ex: 50% mulheres).

Bola de Neve

Participantes indicam outros. Útil para populações ocultas ou de difícil acesso.

Intencional / Julgamento

Pesquisador seleciona casos que considera representativos ou informativos.

Viés de Seleção: quando a amostra não representa a população real — invalida as conclusões. Cuidado com pesquisas online (só alcançam quem tem acesso à internet).

Ética na Coleta e Privacy by Design — LGPD

Qualidade dos Dados

Estabeleça padrões claros antes da coleta. Implemente regras de validação e verificações automatizadas.

Escalabilidade

Use arquiteturas distribuídas (cloud, Kafka, Spark) para capturar grandes volumes sem perder performance.

Privacidade e Compliance

LGPD, GDPR, CCPA, HIPAA evoluem. Privacy by Design: incorpore a privacidade desde o projeto.

Complexidade

Use APIs padrão e frameworks de metadados bem documentados para padronizar fontes heterogêneas.

Princípios da LGPD (Lei 13.709/2018) + Privacy by Design

✓ Consentimento Informado:	Participantes devem conhecer e concordar explicitamente com o uso de seus dados
✓ Minimização de Dados:	Coletar APENAS o que é necessário para o objetivo declarado — nada além
✓ Privacidade e Confidencialidade:	Anonimizar dados sensíveis, proteger identidades, criptografar em trânsito
✓ Segurança dos Dados:	Controle de acesso robusto, criptografia, prevenção de vazamentos, auditorias
✓ Privacy by Design:	Incorporar proteção de dados DESDE A CONCEPÇÃO do sistema, não como correção posterior

Tendências Emergentes na Coleta de Dados

A coleta de dados se torna mais inteligente, rápida e conectada com novas tecnologias e paradigmas arquiteturais.

Coleta com IA

IA/ML identificam novas fontes, classificam múltiplas entradas e sinalizam problemas de qualidade antes que se espalhem. Menos trabalho manual, coleta mais rápida e resultados mais confiáveis.

Ex: LLMs extraindo dados de texto não estruturado; modelos de visão computacional analisando imagens

Edge Computing

Bilhões de dispositivos IoT processam dados ONDE são criados, na 'borda'. Reduz latência, economiza largura de banda e melhora a segurança de dados sensíveis.

Ex: câmeras industriais com inferência local, wearables médicos, veículos autônomos

Streaming em Tempo Real

Os dados agora se movem em fluxo constante — insights gerados quase instantaneamente, sem esperar uploads agendados. Organizações respondem em tempo real à medida que os eventos ocorrem.

Ex: Apache Kafka, AWS Kinesis, Google Pub/Sub — detecção de fraudes em milissegundos

Plataformas Unificadas

Plataformas extraem dados de múltiplos sistemas para uma única estrutura compartilhada (Lakehouse). Facilita governança, consistência e gerenciamento de privacidade em larga escala.

Ex: Databricks Lakehouse, Snowflake, Delta Lake — unifica batch + streaming + ML

Data Warehouse · Data Lake · Lakehouse · Padrões e Escolhas

Data Warehouse, Data Lake e Lakehouse

DATA WAREHOUSE

- Dados estruturados, esquema rígido (schema-on-write)
- Alto desempenho para consultas SQL analíticas
- ACID: atomicidade, consistência, isolamento, durabilidade
- Otimizado para BI e relatórios corporativos
- Dados limpos e transformados ANTES de entrar (ETL)
- Custo: alto — infraestrutura dedicada e licenciamento

SQL Server · Oracle · Redshift · BigQuery · Snowflake

Use quando: relatórios estruturados e BI com dados limpos

DATA LAKE

- Armazena dados brutos de qualquer tipo e formato
- Schema-on-read: estrutura definida no momento da leitura
- Alta flexibilidade — estruturado, semiestruturado e não estruturado
- Custo baixo de armazenamento (object storage em cloud)
- Dados carregados brutos — transformação posterior (ELT)
- Risco: 'data swamp' se sem governança adequada

AWS S3 · Azure Data Lake · Google Cloud Storage · HDFS

Use quando: exploração, ML, dados não estruturados, grande volume

LAKEHOUSE

- Combina flexibilidade do Data Lake + confiabilidade do DW
- Delta Lake: ACID em cima de object storage
- Suporta SQL, ML e streaming na mesma plataforma
- Arquitetura em camadas: Bronze → Silver → Gold
- Schema enforcement + schema evolution — equilíbrio
- Governança centralizada com Unity Catalog (Databricks)

Databricks Delta Lake · Apache Iceberg · Apache Hudi

Use quando: precisa de ML + BI + streaming na mesma infra

Arquitetura em Camadas — Bronze, Silver e Gold

Padrão de organização de dados no Lakehouse (Databricks Delta Lake) — garante rastreabilidade e qualidade progressiva dos dados.

BRONZE LAYER

Dados brutos, como chegaram da fonte. Zero transformação.

- Cópia fiel da fonte (raw data)
- Imutável — nunca modifique dados brutos
- Inclui todos os erros, duplicatas e inconsistências
- Auditabilidade: sempre é possível reconstruir etapas posteriores

CSV, JSON, Parquet bruto, Delta Lake

SILVER LAYER

Dados limpos, padronizados e validados para uso analítico.

- Duplicatas removidas, valores nulos tratados
- Tipos de dados corrigidos e padronizados
- Chaves de negócio aplicadas e FK validadas
- Pronto para consumo por analistas e data scientists

Delta Lake com schema enforcement

GOLD LAYER

Dados agregados e enriquecidos prontos para dashboards e ML.

- Métricas de negócio calculadas (KPIs, receita, etc.)
- Tabelas fato e dimensão do Data Warehouse
- Otimizado para consultas de BI (Power BI, Tableau)
- Features prontas para treinamento de modelos de ML

Delta Lake · Star Schema · Feature Store

Quando Usar Cada Arquitetura — Guia de Decisão

Critério	Data Warehouse	Data Lake	Lakehouse
Volume de dados	GBs a TBs moderados	TBs a PBs	TBs a PBs
Tipo de dado	Estruturado	Qualquer tipo	Qualquer tipo
Schema	Rígido (write)	Flexível (read)	Ambos (enforced + evolution)
Caso de uso principal	BI e relatórios SQL	ML, exploração, raw data	BI + ML + streaming unificados
Custo	Alto (infra dedicada)	Baixo (object storage)	Médio (cloud + Delta)
Governança	Forte nativa	Requer esforço adicional	Unity Catalog (Databricks)
Ferramenta referência	Snowflake · BigQuery	AWS S3 · Azure ADLS	Databricks · Apache Iceberg

executivos, Data Lake para ML e exploração, e Lakehouse como camada unificada.

Agenda — O que você vai revisar hoje

01 Coleta de Dados

Conceito, pipeline, tipos, métodos, ética e LGPD

02 ETL e ELT

Diferenças, Databricks, Pentaho e casos de uso

03 Manipulação de Dados

Limpeza, transformação, integração e EDA

04 Regex

Metacaracteres, módulo re, validação e extração

05 Modelagem Preditiva

Regressão, árvores, métricas, overfitting e k-Fold

06 Lean Startup

Build-Measure-Learn, hipótese, MVP de Data Science

07 Questões de Revisão

10 questões com gabarito comentado




Conceito · Pipeline · Tipos · Métodos · Ética

Coleta de Dados — Conceito e Pipeline

É o processo sistemático de reunir dados brutos de fontes diversas para análise e geração de insights.

O Pipeline de Dados



💡 **Coleta = 'o quê coletar' | Ingestão = 'como transportar'**

Por que é importante? → Tomada de decisões baseada em evidências • Identificação de padrões • Construção de modelos preditivos

Tipos de Dados e Métodos de Coleta

Tipos de Dados

QUALITATIVOS

- Descrevem qualidades ou características
- Ex: opiniões, cores, categorias
- Métodos: entrevistas, grupos focais, observação

QUANTITATIVOS

- Representam quantidades mensuráveis
- Ex: altura, vendas, temperatura
- Métodos: questionários, sensores, APIs

Métodos de Coleta

Primários

Surveys, entrevistas, experimentos, testes A/B — direto na fonte

Secundários

Logs internos, datasets públicos, relatórios governamentais

Automatizados

IoT, web scraping (BeautifulSoup), APIs (Twitter, Open Data), Kafka

Desafios na Coleta e Ética — LGPD

Qualidade

Dados incompletos, inconsistentes ou enviesados comprometem análises

Escalabilidade

Grandes volumes exigem infraestrutura distribuída e performante

Privacidade

LGPD/GDPR exigem consentimento e proteção de dados pessoais

Complexidade

Integrar múltiplas fontes heterogêneas requer padronização

Ética na Coleta — Princípios LGPD (Lei 13.709/2018)

- ✓ Consentimento Informado — participantes devem conhecer e concordar com o uso
- ✓ Privacidade e Confidencialidade — anonimizar dados sensíveis
- ✓ Minimização de Dados — coletar apenas o necessário para o objetivo
- ✓ Segurança dos Dados — criptografia, controle de acesso e prevenção de vazamentos



Extract · Transform · Load vs Extract · Load · Transform

ETL vs ELT — Comparativo

ETL



Transforma em área staging ANTES de carregar

ELT



Transforma DENTRO do destino (cloud) após carregar

Critério	ETL	ELT
Onde transforma?	Servidor staging / intermediário	Dentro do destino (Data Warehouse cloud)
Volume de dados	Adequado a volumes médios (GBs)	Escala para Big Data (TBs, PBs)
Custo de infraestrutura	Maior — servidor dedicado	Menor — usa infra do destino
Ferramentas	Pentaho, Talend, SSIS	Databricks, dbt, BigQuery, Snowflake
Quando usar?	DW relacional legado / dados sensíveis	Data Lake, cloud, real-time streaming

Ferramentas — Databricks e Pentaho

DATABRICKS — Plataforma ELT (Cloud)

- Criado pelos autores do Apache Spark
- Arquitetura Delta Lake: Bronze → Silver → Gold
- Suporta Python, Scala, SQL e R
- Disponível em AWS, Azure e GCP
- Ideal: Big Data, streaming, ML avançado

PENTAHO PDI — ETL Visual (Open-Source)

- Interface drag-and-drop (Spoon / Kettle)
- Conectores nativos: MySQL, Excel, CSV, API
- Steps: CSV Input → Filter → Transform → Output
- Gratuito (versão community)
- Ideal: DW relacional, dados médios, BI

Arquitetura Delta Lake (Databricks)

BRONZE

Dados brutos carregados sem transformação

SILVER

Dados limpos e padronizados para uso analítico

GOLD

Dados agregados prontos para dashboards e ML



Limpeza · Transformação · Integração · Validação · EDA

Pipeline de Dados — 6 Etapas (CRISP-DM)

80% do tempo em Ciência de Dados é gasto na preparação dos dados.



Coleta

APIs, BD, Arquivos, Streams



Exploração

EDA, estatísticas descritivas



Limpeza

Valores ausentes, duplicatas, outliers



Transformação

Normalização, encoding, feature engineering



Integração

Merge, join, consolidação de fontes



Validação

Qualidade, testes, schemas

Limpeza de Dados — Valores Ausentes, Outliers e Duplicatas

VALORES AUSENTES

- Remoção: indicada quando < 5% ausente
- `df.dropna(subset=['renda'])`
- Imputação: média/mediana (numérico), moda (cat.)
- `df.fillna(df.mean())`

OUTLIERS

- Z-score: $|z| > 3 \rightarrow$ outlier
- IQR: $< Q1 - 1.5 \times IQR$ ou $> Q3 + 1.5 \times IQR$
- $IQR = Q3 - Q1$
- Verificar se é erro ou evento raro legítimo

DUPLICATAS

- `df.duplicated().sum()` # conta
- `df.drop_duplicates(subset=['cpf'])`
- Fuzzy: Levenshtein / Record Linkage
- Causas: ingestão múltipla, integração

Inconsistências de Tipo e Formato

```
df['data'] = pd.to_datetime(df['data'], dayfirst=True)
```

```
df['valor'] = pd.to_numeric(df['valor'], errors='coerce')
```

```
df.dtypes    # verificar tipos    |    df.info()    # visão geral
```

Transformação, Integração e Joins

Transformação

Normalização / Escalonamento

Min-Max → [0,1] | Z-score → média 0, desvio 1 | Robust Scaler → resistente a outliers

Encoding Categórico

Label Encoding (ordinal: baixo/médio/alto) | One-Hot Encoding (nominal: cria coluna por categoria)

Feature Engineering

Extrair dia/mês/ano | Interações: $x_1 \times x_2$ | Binning: `pd.cut()` / `pd.qcut()`

Integração — Tipos de Join

INNER JOIN

Apenas registros com correspondência nos dois lados

LEFT JOIN

Todos da esquerda + correspondências da direita (NaN onde ausente)

OUTER JOIN

Todos os registros de ambos os lados

CONCAT

Empilhamento vertical/horizontal — `pd.concat([df1, df2])`

EDA — Estatísticas Descritivas

Tendência Central

Média, mediana, moda — cada uma adequada a diferentes distribuições

Dispersão

Variância, desvio padrão (σ), IQR, coeficiente de variação (CV%)

Assimetria/Curtose

Skewness (desvio da simetria) e Kurtosis (caudas)

Correlação

Pearson (linear), Spearman (monótona), Kendall (ordinal)

Visualizações

Histograma, Boxplot, Scatter Plot, Heatmap de correlação

Ferramentas Python

pandas-profiling, matplotlib/seaborn, Plotly, sweetviz



Expressões Regulares para Tratamento de Dados

Regex — Conceitos Básicos e Metacaracteres

Expressão Regular = sequência de caracteres que define um padrão de busca em textos.

Metacaracteres e Classes

.	Qualquer caractere (exceto nova linha)
\d	Dígito [0-9] \D → não dígito
\w	Palavra [a-zA-Z0-9_] \W → não palavra
\s	Espaço em branco \S → não espaço
[abc]	a, b ou c [^abc] → nenhum desses
[a-z]	Letra minúscula [A-Z] maiúscula

Quantificadores e Âncoras

*	Zero ou mais repetições
+	Uma ou mais repetições
?	Zero ou uma (opcional)
{n,m}	Entre n e m repetições
^ \$	Início e fim da string
\b	Limite de palavra
()	Grupo de captura
.*?	Preguiçoso (mínimo possível)

Regex no Python — Módulo re e Aplicações Práticas

Funções do módulo re

<code>re.match()</code>	Busca no INÍCIO da string
<code>re.search()</code>	Busca em qualquer posição
<code>re.findall()</code>	Retorna lista de todas as ocorrências
<code>re.sub()</code>	Substitui ocorrências por texto
<code>re.split()</code>	Divide a string pelo padrão
<code>re.compile()</code>	Compila padrão para reutilização

Aplicações com Dados

Validar e-mail:	<code>r'^[\w.-]+@[\w.-]+\.[a-z]{2,}\$'</code>
Validar CPF:	<code>r'\d{3}\.\d{3}\.\d{3}-\d{2}\$'</code>
Validar CEP:	<code>r'\d{5}-\d{3}\$'</code>
Limpar telefone:	<code>re.sub(r'^0-9', '', fone)</code>
Remover HTML:	<code>re.sub(r'<[^>]+>', '', html)</code>
Extrair datas:	<code>re.findall(r'\d{2}/\d{2}/\d{4}', texto)</code>
Extrair e-mails:	<code>re.findall(r'[\w.-]+@[\w.-]+', texto)</code>
Converter data:	<code>re.sub(r'(\d{4})-(\d{2})-(\d{2})', r'\3/\2/\1', d)</code>



Regressão · Árvores · Métricas · Overfitting · k-Fold

Regressão Linear e Logística

REGRESSÃO LINEAR — Target Contínuo

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$$

Pressupostos:

- Linearidade entre X e y
- Independência dos resíduos
- Homoscedasticidade (variância constante dos erros)
- Normalidade dos resíduos

Usos: preço de imóvel, previsão de demanda, ciências naturais

REGRESSÃO LOGÍSTICA — Classificação Binária

$$P(y=1|X) = 1 / (1 + e^{-z}) \quad (\text{sigmoide})$$

Como funciona:

- Gera probabilidade P entre 0 e 1 para cada obs.
- Aplica limiar (default 0.5) → classifica positivo/negativo
- Interpreta coeficientes como log-odds
- Regularização L1 (Lasso) ou L2 (Ridge) → evita overfitting

Usos: churn, fraude, diagnóstico, score de crédito, spam

💡 **Regressão Linear → target CONTÍNUO | Regressão Logística → target CATEGÓRICO (apesar do nome)**

Métricas: MAE, RMSE, R^2 (regressão) | Precisão, Recall, F1, AUC-ROC (classificação)

Árvore de Decisão e Random Forest

ÁRVORE DE DECISÃO



Nó Raiz

Variável com maior poder de separação (menor impureza — Gini/Entropia)



Nós Internos

Perguntas sobre subconjuntos → dividem dados por condição



Folhas

Decisão final: classe majoritária ou média do target

✓ Alta interpretabilidade | ✓ Não exige normalização
X Overfitting sem controle | X Instável a pequenas mudanças

RANDOM FOREST

1. Bootstrap Sampling

Para cada árvore: sorteia com reposição um subconjunto de linhas → garante diversidade

2. Feature Randomness

Em cada split: considera apenas $\sqrt{p}$ variáveis aleatórias → evita que todas as árvores copiem a mesma lógica

3. Agregação Final

Classificação: voto majoritário | Regressão: média das predições → reduz variância



RF supera a árvore isolada: mais robusta ao overfitting e instabilidade

Usos: detecção de fraude, scoring de crédito, diagnóstico médico, seleção de features (feature importances)

Métricas de Avaliação e Overfitting / Underfitting

Regressão

MAE

Média dos |erros| — mesma unidade do target, robusta a outliers

RMSE

$\sqrt{\text{média dos erros}^2}$ — penaliza erros grandes (inaceitáveis em estoque)

R^2

Proporção da variância explicada. 1=perfeito, 0=igual à média

Classificação — Matriz de Confusão

	Prev. POS	Prev. NEG
Real POS	VP ✓	FN ✗
Real NEG	FP ✗	VN ✓

Acurácia:

$(VP+VN)/\text{Total}$ — enganosa em classes desbalanceadas

Precisão:

$VP/(VP+FP)$ — dos classificados positivos realmente são

Recall:

$VP/(VP+FN)$ — dos positivos reais, qu

detectados (crítico em diagnósticos)

F1-Score:

$2 \times (P \times R) / (P + R)$ — harmônica de precis

Trade-off Viés-Variância



UNDERFITTING

(Alto Viés)

Modelo simples demais. Erro alto em treino E teste. Solução: + complexidade, + features, menos regularização



PONTO IDEAL

(Equilíbrio)

Erro baixo em treino E teste. Generaliza bem. Encontrado via k-Fold + GridSearchCV



OVERFITTING

(Alta Variância)

Memoriza o treino. Erro baixo no treino, ALTO no teste. Solução: regularização L1/L2, mais dados, pruning

Validação Cruzada k-Fold

Por que k-Fold?

Fornecer estimativa mais estável do desempenho — especialmente em datasets pequenos ou desbalanceados.

Iter 1	TESTE	Treino	Treino	Treino
Iter 2	Treino	TESTE	Treino	Treino
Iter 3	Treino	Treino	TESTE	Treino
Iter 4	Treino	Treino	Treino	TESTE
Iter 5	Treino	Treino	Treino	Treino

→ Métrica final = média dos 5 scores $\pm$ desvio padrão

```
from sklearn.model_selection import  
cross_val_score,  
StratifiedKFold
```

```
skf = StratifiedKFold(  
    n_splits=5,  
    shuffle=True,  
    random_state=42)
```


```
scores = cross_val_score(  
    modelo, X, y,  
    cv=skf,  
    scoring='f1')
```



Metodologia para Projetos de Data Science

Lean Startup — Build · Measure · Learn

"A aprendizagem validada é a unidade de progresso." — Eric Ries



- ◆ Comece pelo PROBLEMA, não pelo dado — o dataset é ferramenta, não ponto de partida
- ◆ MVP = menor versão funcional que valida a hipótese | Pivotar NÃO é falhar — é aprender
- ◆ Estrutura da hipótese: 'Acredito que [X] está relacionado com [Y] e é possível [análise] com [métrica]'



10 questões com gabarito comentado

Questões 01 e 02

Questão 01 — Coleta de Dados

Em um pipeline de dados, qual é a diferença correta entre COLETA e INGESTÃO?

- A) Coleta e ingestão são sinônimos — ambas se referem ao processo de reunir dados.
- B) Coleta = 'o que' reunir de fontes diversas; Ingestão = 'como' transportar e receber os dados.
- C) Coleta armazena os dados; ingestão os analisa.
- D) Ingestão ocorre antes da coleta no pipeline de dados.

Questão 02 — Coleta de Dados

Qual princípio da LGPD estabelece que só se deve coletar os dados estritamente necessários para o objetivo definido?

- A) Consentimento Informado
- B) Segurança dos Dados
- C) Minimização de Dados
- D) Confidencialidade

Questões 03 e 04

Questão 03 — ETL e ELT

No ETL, onde ocorre a transformação dos dados? No ELT, onde ela acontece?

- A) ETL: dentro do Data Warehouse (cloud). ELT: em uma área staging externa.
- B) ETL: em uma área staging externa ao destino. ELT: dentro do próprio destino.
- C) Ambas as abordagens transformam dentro do servidor ETL dedicado.
- D) A ordem de extração, transformação e carga é a mesma nos dois paradigmas.

Questão 04 — Manipulação de Dados

Ao usar o scikit-learn para pré-processar dados, qual é a regra fundamental para evitar data leakage?

- A) Aplicar fit() e transform() em todo o dataset antes de dividir em treino/teste.
- B) Usar fit() apenas no conjunto de treino e transform() separadamente em treino e teste.
- C) Normalizar apenas as variáveis categóricas; as numéricas não precisam de fit.
- D) Dividir em treino e teste após o encoding One-Hot para garantir consistência.

Questões 05 e 06

Questão 05 — Manipulação de Dados

Qual método de detecção de outliers utiliza quartis e é robusto a distribuições assimétricas?

- A) Z-score ($|z| > 3$)
- B) Regra do IQR ($< Q1 - 1.5 \times IQR$ ou $> Q3 + 1.5 \times IQR$)
- C) Pearson correlation
- D) Skewness > 2

Questão 06 — Regex

Qual expressão regular valida corretamente um CPF no formato 000.000.000-00?

- A) `r'^\d{9}-\d{2}$'`
- B) `r'^\d{3}\.\d{3}\.\d{3}-\d{2}$'`
- C) `r'^[0-9]{11}$'`
- D) `r'^\w{3}.\w{3}.\w{3}-\w{2}$'`

Questões 07 e 08

Questão 07 — Regex

Qual função do módulo `re` substitui todas as ocorrências de um padrão por outro texto?

- A) `re.search()`
- B) `re.findall()`
- C) `re.sub()`
- D) `re.match()`

Questão 08 — Modelagem Preditiva

Em um modelo de classificação para detecção de fraudes, qual métrica é mais crítica para minimizar fraudes não detectadas?

- A) Acurácia — maximiza o total de predições corretas
- B) Precisão — minimiza o número de falsos positivos
- C) Recall (Sensibilidade) — minimiza o número de falsos negativos (fraudes não detectadas)
- D) R^2 — mede a proporção da variância explicada

Questões 09 e 10

Questão 09 — Modelagem Preditiva

O que acontece com um modelo em overfitting quando avaliado em dados novos?

- A) Apresenta erro baixo tanto no treino quanto no teste.
- B) Apresenta erro alto no treino e baixo no teste.
- C) Apresenta erro baixo no treino, mas alto no teste — não generaliza.
- D) Apresenta erro alto em ambos — é indiferente ao padrão nos dados.

Questão 10 — Lean Startup

No contexto do Projeto Integrador, o que representa o MVP (Mínimo Produto Viável) em Data Science?

- A) O relatório final completo com todos os modelos e visualizações refinadas.
- B) A menor versão funcional que permite validar a hipótese central e gerar aprendizado real.
- C) O dataset mais completo e limpo possível antes de qualquer análise.
- D) A apresentação final entregue ao professor com todos os critérios cumpridos.

GABARITO GERAL

Q01 Gabarito: B	Q02 Gabarito: C	Q03 Gabarito: B	Q04 Gabarito: B	Q05 Gabarito: B
Q06 Gabarito: B	Q07 Gabarito: C	Q08 Gabarito: C	Q09 Gabarito: C	Q10 Gabarito: B

Comentários Seleccionados

Q04 — Data Leakage

fit() SOMENTE no treino; transform() em treino e teste separadamente.

Q08 — Recall em Fraudes

FN (fraude não detectada) é mais custoso → priorizar Recall.

Q09 — Overfitting

Erro baixo no treino, ALTO no teste → o modelo memorizou o ruído.

Q10 — MVP em DS

A menor entrega que valida a hipótese — não é o projeto final.



Revise os conceitos, pratique os exercícios e boa prova!

Coleta de Dados • ETL / ELT • Manipulação • Regex • Modelagem Preditiva • Lean Startup